



Métodos Numéricos PM 311 A

Sistemas de Ecuaciones Lineales: Métodos Directos e Iterativos

<https://pm-311.github.io>

Prof. Fidel Jara Huanca

Facultad de Ingeniería de Petróleo, Gas Natural y Petroquímica, Universidad Nacional de Ingeniería

Martes, 15 de septiembre de 2026

Índice

Motivación y Modelado Matricial

Métodos Directos y Factorizaciones

Condicionamiento y Análisis de Sensibilidad

Métodos Iterativos Estacionarios (GLIS)

Teoría Espectral de Convergencia

Competencias de la sesión

Al finalizar la clase, el estudiante de ingeniería:


1. **Formula y clasifica** sistemas de ecuaciones algebraicas lineales $Ax = b$ provenientes de modelos físicos de ingeniería y transporte en medios porosos.
2. **Aplica y analiza** métodos directos de factorización (LU , Cholesky) y reconoce el papel crítico del pivoteo escalado para la estabilidad numérica.
3. **Evalúa el condicionamiento** $\kappa(A)$ y cuantifica la discrepancia entre la norma del residuo y el error relativo de la solución calculada.
4. **Implementa esquemas iterativos** estacionarios clásicos (Jacobi, Gauss-Seidel, Richardson) enmarcados en la teoría general de splitting (GLIS).
5. **Demuestra condiciones de convergencia** mediante el radio espectral $\rho(T_M) < 1$ y criterios de dominancia diagonal.



Figura: Descarga de diapositivas y código en Python.

Motivación Física: Red de distribución de flujo y presiones nodales

En ingeniería de yacimientos y transporte por tuberías, la distribución estacionaria de presiones en una red interconectada de nodos obedece al balance de masa y la ley de flujo (Darcy / Hagen-Poiseuille):



Para cada nodo i , el caudal neto acumulado es nulo:

$$\sum_{j \in \mathcal{V}(i)} c_{ij} (P_i - P_j) = q_i^{\text{net}}.$$

Sistema Lineal Estructurado

Agrupando las presiones nodales $x = [P_1, P_2, \dots, P_n]^T$, se obtiene:

$$Ax = b, \quad A \in \mathbb{R}^{n \times n}, \quad b \in \mathbb{R}^n. \quad (2)$$

donde la matriz de coeficientes A exhibe propiedades estructurales fundamentales:

- **Simetría:** $a_{ij} = a_{ji} = -c_{ij}$ para $i \neq j$.
- **Diagonal dominante:** $a_{ii} = \sum_{j \neq i} c_{ij}$.
- **Esparsidad (Sparsity):** La inmensa mayoría de entradas son nulas ($a_{ij} = 0$) cuando no existe conexión física directa.

La disyuntiva del cálculo numérico

- (1) ¿Conviene resolver $Ax = b$ mediante métodos **directos** (álgebra finita exacta salvo redondeo) o métodos **iterativos** (aproximaciones sucesivas)?

Taxonomía de Sistemas Lineales: Dimensiones, esparcidad y factor de llenado (fill-in)

Métodos Directos vs. Métodos Iterativos

Directos (Gauss, LU, Cholesky): Computan la solución exacta en un número finito de operaciones aritméticas en aritmética de precisión infinita.

- Ideales para matrices densas de tamaño moderado ($n \leq 10^4$).
- En matrices esparcidas causan **llenado** (*fill-in*): ceros originales se transforman en entradas no nulas, saturando la memoria RAM.

Iterativos (Jacobi, Gauss-Seidel, Gradiente Conjugado): Generan una secuencia $\{x^{(k)}\}_{k=0}^\infty$ tal que $x^{(k)} \rightarrow x^*$.

- Preservan la esparcidad (solo requieren productos matriz-vector Av).
- Imprescindibles para simulaciones 3D donde $n \sim 10^6 - 10^8$.

Complejidad Computacional Teórica

Para un sistema con $A \in \mathbb{R}^{n \times n}$:

Método	Flops Operacionales	Memoria Requerida
Eliminación Gauss / LU	$\frac{2}{3}n^3 + \mathcal{O}(n^2)$	$\mathcal{O}(n^2)$ (densa)
Cholesky (A SPD)	$\frac{1}{3}n^3 + \mathcal{O}(n^2)$	$\frac{1}{2}n^2$
Thomas (Tridiagonal)	$5n$	$\mathcal{O}(n)$
Paso Iterativo (Esparcido)	$\mathcal{O}(\text{nnz}(A))$	$\mathcal{O}(\text{nnz}(A))$

Preguntas esenciales de diseño algorítmico

1. ¿Cuándo un método directo es numéricamente estable?
2. ¿Cómo influyen las perturbaciones en los datos A y b ?
3. ¿Bajo qué condiciones converge un esquema iterativo?

Eliminación Gaussiana y Operaciones Elementales: Matriz aumentada, operaciones por filas y forma escalonada (REF)

Operaciones Elementales por Filas (EROs – [4])

Para resolver el sistema lineal $Ax = b$, se construye la matriz aumentada $(A \mid b) \in \mathbb{R}^{n \times (n+1)}$. Las tres operaciones elementales que preservan el conjunto solución son:

- **Tipo I (Intercambio):** Intercambiar dos filas ($R_i \leftrightarrow R_j$).
- **Tipo II (Escalaiento):** Multiplicar una fila por un escalar no nulo ($R_i \leftarrow cR_i$, $c \neq 0$).
- **Tipo III (Eliminación):** Sumar a una fila un múltiplo escalar de otra ($R_i \leftarrow R_i - m_{ik}R_k$).

El objetivo es reducir $(A \mid b)$ a la **forma escalonada por filas** (Row Echelon Form, REF) $(U \mid \tilde{b})$.

Algoritmo y Sustitución Regresiva ([2, 4])

Para $k = 1, \dots, n - 1$, los multiplicadores son:

$$m_{ik} := \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}, \quad (i = k + 1, \dots, n), \quad (3)$$

aplicando $R_i \leftarrow R_i - m_{ik}R_k$. Luego, se despejan las incógnitas desde x_n hasta x_1 :

$$x_n = \frac{\tilde{b}_n}{u_{nn}}, \quad x_i = \frac{1}{u_{ii}} \left(\tilde{b}_i - \sum_{j=i+1}^n u_{ij}x_j \right). \quad (4)$$

Interpretación Matricial ([1])

Cada etapa equivale a $M_k = I - m_k e_k^T$, tal que $M_{n-1} \cdots M_1 A = U$.

Estrategias de Pivoteo: Pivoteo Parcial y Pivoteo Parcial Escalado (SPP)

Falla por escala en pivoteo simple

Considere en aritmética de 3 dígitos de mantisa:

$$\begin{bmatrix} 0.0001 & 1.000 \\ 1.000 & 1.000 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.000 \\ 2.000 \end{bmatrix}.$$

Multiplicador $m_{21} = \frac{1.000}{0.0001} = 10^4$. La segunda ecuación produce:

$$(1 - 10^4)x_2 = 2 - 10^4 \implies -10^4 x_2 = -10^4 \implies x_2 = 1.$$

Luego $x_1 = \frac{1-1(1)}{0.0001} = 0$, ¡cuando la solución exacta es $x_1 \approx 1.0001$, $x_2 \approx 0.9999$! (100 % de error).

Pivoteo Parcial Escalado (SPP – [2])

Evita el sesgo por unidades físicas heterogéneas sin intercambiar físicamente las filas en memoria:

1. Vector de escala inicial:

$$s_i := \max_{1 \leq j \leq n} |a_{ij}|, \quad (i = 1, \dots, n). \quad (5)$$

2. Vector de índices (permutación): $p = [1, 2, \dots, n]^T$.

3. En el paso k , se busca el renglón candidato $\ell \geq k$ tal que:

$$\frac{|a_{p_\ell, k}|}{s_{p_\ell}} = \max_{k \leq i \leq n} \frac{|a_{p_i, k}|}{s_{p_i}}. \quad (6)$$

4. Se intercambian únicamente los punteros $p_k \leftrightarrow p_\ell$.

Descomposición LU (Algoritmo de Doolittle): Formulación explícita de coeficientes y sustituciones ([5])

Fórmulas Explícitas de Factorización ([5])

Fijando $\ell_{ii} = 1$ en $A = LU$, para cada columna $j = 1, \dots, n$:

$$u_{ij} = a_{ij} - \sum_{k=1}^{i-1} \ell_{ik} u_{kj}, \quad (i = 1, \dots, j), \quad (7)$$

$$\ell_{ij} = \frac{1}{u_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} \ell_{ik} u_{kj} \right), \quad (i = j+1, \dots, n). \quad (8)$$

El término diagonal u_{jj} actúa como pivote ($u_{jj} \neq 0$). Con pivoteo general: $PA = LU$ ([1]).

Algoritmo de Solución en Dos Fases ([5])

Para resolver $Ax = b$ una vez conocido $A = LU$:

1. Sustitución progresiva ($Ly = b$):

$$y_1 = b_1, \quad y_i = b_i - \sum_{j=1}^{i-1} \ell_{ij} y_j, \quad (i = 2, \dots, n). \quad (9)$$

2. Sustitución regresiva ($Ux = y$):

$$x_n = \frac{y_n}{u_{nn}}, \quad x_i = \frac{1}{u_{ii}} \left(y_i - \sum_{j=i+1}^n u_{ij} x_j \right). \quad (10)$$

Estructuras Especiales: Cholesky y Thomas: Explotando simetría, positividad y bandas estrechas

Factorización de Cholesky (A SPD)

Si $A = A^T$ y es definida positiva ($x^T A x > 0, \forall x \neq 0$):

$$A = LL^T, \quad (11)$$

donde L es triangular inferior con elementos diagonales estrictamente positivos:

$$\ell_{kk} = \sqrt{a_{kk} - \sum_{j=1}^{k-1} \ell_{kj}^2},$$
$$\ell_{ik} = \frac{1}{\ell_{kk}} \left(a_{ik} - \sum_{j=1}^{k-1} \ell_{ij} \ell_{kj} \right), \quad i > k.$$

Propiedades clave:

- Costo: $\frac{1}{3}n^3$ flops ($\frac{1}{2}$ del costo de LU).
- **Estabilidad incondicional:** No requiere pivoteo.

Sistemas Tridiagonales: Algoritmo de Thomas

Surgen en diferencias finitas para difusión unidimensional:

$$\begin{bmatrix} d_1 & c_1 & & \\ a_1 & d_2 & c_2 & \\ & \ddots & \ddots & \ddots \\ & & a_{n-1} & d_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

(12) Algoritmo en $\mathcal{O}(n)$ flops ([2]):

- Modificación hacia adelante: $d'_i = d_i - \frac{a_{i-1}}{d'_{i-1}} c_{i-1}$,

$$b'_i = b_i - \frac{a_{i-1}}{d'_{i-1}} b'_{i-1}.$$

- Sustitución regresiva: $x_n = \frac{b'_n}{d'_n}$, $x_i = \frac{b'_i - c_i x_{i+1}}{d'_i}$.

Normas Matriciales y Número de Condición: Midiendo la amplificación intrínseca de incertidumbres

Normas Inducidas o Subordinadas

Dada una norma vectorial $\|\cdot\|$, la norma matricial inducida se define como:

$$\|A\| := \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|. \quad (14)$$

Casos fundamentales en computación:

- $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$ (máxima suma por columnas).
- $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$ (máxima suma por filas).
- $\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \sigma_{\max}(A)$ (valor singular máximo).

Definición 1 (Número de Condición de una Matriz ([1])).

Para $A \in \mathbb{R}^{n \times n}$ no singular:

$$\kappa(A) := \|A\| \|A^{-1}\|. \quad (15)$$

Propiedades esenciales:

- $\kappa(A) \geq \|AA^{-1}\| = \|I\| = 1$.
- $\kappa(I) = 1$.
- Para matrices ortogonales Q : $\kappa_2(Q) = 1$.

Significado Físico y Numérico

$\kappa(A)$ cuantifica la sensibilidad del sistema frente a perturbaciones en los datos. Una regla empírica fundamental: si $\kappa_{10}(A) \approx 10^p$, se pierden hasta p cifras significativas de precisión en la solución calculada.

Teorema de Perturbación y Residuo vs. Error: ¿Un residuo pequeño garantiza una solución precisa?

Teorema 2 (Cota Fundamental del Error Relativo).

Sea $Ax = b$ y $(A + \Delta A)(x + \Delta x) = b + \Delta b$. Si $\|\Delta A\| < \frac{1}{\|A^{-1}\|}$, entonces:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right). \quad (16)$$

En particular, si solo se perturba el vector de carga b ($\Delta A = 0$):

$$\frac{\|\Delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\Delta b\|}{\|b\|}. \quad (17)$$

La Paradoja del Residuo ([1, 2])

Sea $\hat{x}$ una solución aproximada. Definimos:

- **Vector de error:** $e := x - \hat{x}$.
- **Vector de residuo:** $r := b - A\hat{x} = A(x - \hat{x}) = Ae$.

Como $e = A^{-1}r$, acotamos:

$$\frac{1}{\kappa(A)} \frac{\|r\|}{\|b\|} \leq \frac{\|e\|}{\|x\|} \leq \kappa(A) \frac{\|r\|}{\|b\|}. \quad (18)$$

Conclusión Crucial

Si $\kappa(A) \gg 1$ (sistema mal condicionado), un algoritmo puede producir un residuo insignificante ($\|r\| \approx 10^{-14}$) teniendo un error inaceptable ($\|e\| \approx 10^{-2}$). ¡Monitorear solo el residuo es engañoso!

Esquemas Lineales Iterativos Generales (GLIS): El marco formal del desdoblamiento matricial (Splitting)

Teoría del Desdoblamiento ([3])

Para resolver $Ax = b$, consideramos un **splitting**:

$$A = M - N, \quad (19)$$

donde $M \in \mathbb{R}^{n \times n}$ es una matriz **no singular** y fácil de invertir.

Entonces:

$$(M - N)x = b \iff Mx = Nx + b. \quad (20)$$

Esto induce de forma natural el esquema iterativo:

$$Mx^{(k+1)} = Nx^{(k)} + b, \quad k \geq 0.$$

Definición 3 (Matriz de Transferencia de Error ([3])).

Multiplicando por M^{-1} :

$$x^{(k+1)} = T_M x^{(k)} + c_M, \quad (22)$$

donde:

$$T_M := M^{-1}N = M^{-1}(M - A) = I - M^{-1}A, \quad (23)$$

$$c_M := M^{-1}b. \quad (24)$$

$$(21) \quad T_M \text{ se denomina } \mathbf{matriz de iteraci3n} \text{ o matriz de propagaci3n de error.}$$

Ecuaci3n del Error

Siendo x la soluci3n exacta ($x = T_M x + c_M$) y $e^{(k)} := x^{(k)} - x$:

$$e^{(k+1)} = T_M e^{(k)} = T_M^{k+1} e^{(0)}. \quad (25)$$

Desdoblamiento Canónico y Método de Jacobi: Actualizaciones desacopladas y paralelismo intrínseco

Descomposición Estándar de la Matriz A

Separamos la matriz en sus partes diagonal, triangular inferior y superior:

$$A = D - L - U, \quad (26)$$

donde $D = \text{diag}(a_{ii})$, $-L$ contiene los elementos estrictamente bajo la diagonal y $-U$ sobre ella.

Método de Jacobi ([2, 3])

Tomamos el preconditionador diagonal:

$$M_J := D, \quad N_J := L + U. \quad (27)$$

La matriz de iteración de Jacobi es:

$$T_J = D^{-1}(L + U) = I - D^{-1}A. \quad (28)$$

Fórmula por Componentes de Jacobi

Para cada fila $i = 1, \dots, n$:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right). \quad (29)$$

Ventajas y Desventajas:

- **Totalmente paralelizable:** Cada coordenada $x_i^{(k+1)}$ se calcula de manera independiente sin esperar a las demás.
- Requiere almacenar dos vectores completos en memoria ($x^{(k)}$ y $x^{(k+1)}$).
- Convergencia usualmente lenta en mallas finas.

Método de Gauss-Seidel Progresivo y Regresivo: Aceleración mediante actualización inmediata en memoria

Gauss-Seidel Progresivo (Forward GS)

Aprovecha de inmediato las componentes $x_1^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ ya computadas en el paso actual:

$$M_{GS} := D - L, \quad N_{GS} := U. \quad (30)$$

Forma matricial:

$$(D - L)x^{(k+1)} = Ux^{(k)} + b. \quad (31)$$

Matriz de iteración:

$$T_{GS} = (D - L)^{-1}U. \quad (32)$$

Formulación escalar:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)} \right). \quad (33)$$

Gauss-Seidel Regresivo (Backward GS)

Actualiza las componentes en orden inverso ($i = n, n-1, \dots, 1$):

$$M_{BGS} := D - U, \quad N_{BGS} := L. \quad (34)$$

Comparación Operativa

- **Ahorro de memoria:** Se sobrescribe el vector x *in-place* en un único arreglo.
- **Dependencia secuencial:** No es directamente vectorizable sin coloreado de nodos (Red-Black ordering).
- Típicamente converge el doble de rápido que Jacobi:
 $\rho(T_{GS}) \approx \rho(T_J)^2$.

Método de Richardson y Relajación Amortiguada: Ajuste del tamaño de paso y estabilización de la dinámica

Método de Richardson Clásico ([3])

Se elige $M_\omega = \frac{1}{\omega}I$, donde $\omega > 0$ es un parámetro de paso o relajación:

$$x^{(k+1)} = x^{(k)} + \omega (b - Ax^{(k)}) = x^{(k)} + \omega r^{(k)}. \quad (35)$$

Matriz de iteración:

$$T_\omega = I - \omega A. \quad (36)$$

Interpretación en optimización: Equivale al método del **descenso por gradiente** con paso fijo para minimizar la función cuadrática:

$$\Phi(x) = \frac{1}{2}x^T Ax - x^T b.$$

Jacobi Amortiguado (Damped Jacobi)

Interpola linealmente entre la iteración previa y la propuesta de Jacobi:

$$x^{(k+1)} = (1 - \omega)x^{(k)} + \omega x_J^{(k+1)}. \quad (38)$$

Matriz asociada:

$$T_{J,\omega} = (1 - \omega)I + \omega T_J = I - \omega D^{-1}A. \quad (39)$$

Propiedad Suavizadora (Smoother)

(37) En métodos multigrid, el Jacobi amortiguado (con $\omega = \frac{2}{3}$) no busca resolver el sistema globalmente, sino **amortiguar rápidamente las componentes de alta frecuencia** del error.

El Teorema Espectral de Convergencia: El radio espectral $\rho(T)$ como juez definitivo

Definición 4 (Radio Espectral).

Para cualquier matriz cuadrada $T \in \mathbb{R}^{n \times n}$ con autovalores $\lambda_1, \dots, \lambda_n \in \mathbb{C}$:

$$\rho(T) := \max_{1 \leq i \leq n} |\lambda_i(T)|. \quad (40)$$

Teorema 5 (Teorema Maestro de Convergencia de GLIS).

El esquema iterativo lineal estacionario $x^{(k+1)} = Tx^{(k)} + c$ converge a la solución única $x = (I - T)^{-1}c$ para **cualquier** vector inicial $x^{(0)}$ si y sólo si:

$$\rho(T) < 1. \quad (41)$$

Esquema de la Demostración ([3])

La dinámica del error está regida por:

$$e^{(k)} = T^k e^{(0)}. \quad (42)$$

Por la Forma Canónica de Jordan de $T = VJV^{-1}$:

$$T^k = VJ^kV^{-1}. \quad (43)$$

Los bloques de Jordan asociados a autovalores λ satisfacen:

$$J_i^k \rightarrow 0 \quad (k \rightarrow \infty) \iff |\lambda_i| < 1.$$

Por tanto, $\lim_{k \rightarrow \infty} T^k = 0 \iff \rho(T) < 1$. ■

Tasa Asintótica de Convergencia

La ganancia de dígitos exactos por iteración es:

$$R_\infty(T) := -\log_{10}(\rho(T)). \quad (44)$$

Criterios Prácticos de Convergencia: Matrices diagonalmente dominantes y definidas positivas

Definición 6 (Dominancia Diagonal Estricta por Filas).

Una matriz $A \in \mathbb{R}^{n \times n}$ es estrictamente diagonal dominante (EDD) si:

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad \forall i = 1, \dots, n. \quad (45)$$

Teorema 7 (Criterio Suficiente de Convergencia ([2])).

Si la matriz de coeficientes A es estrictamente diagonal dominante:

1. A es no singular.
2. El método de **Jacobi** converge ($\|T_J\|_\infty < 1 \implies \rho(T_J) < 1$).
3. El método de **Gauss-Seidel** converge ($\rho(T_{GS}) < 1$).

Teorema 8 (Teorema de Householder-John / Ostrowski-Reich).

Si A es una matriz simétrica y definida positiva (SPD), y el factor de desdoblamiento M cumple que $M + M^T - A$ es SPD, entonces:

$$\rho(T_M) < 1. \quad (46)$$

Consecuencia fundamental: Para cualquier matriz SPD, el método de Gauss-Seidel converge **incondicionalmente**, sin importar si es diagonalmente dominante o no.

Cuidado con la intuición

Existen matrices donde Jacobi converge y Gauss-Seidel diverge, y viceversa. La dominancia diagonal o la positividad simétrica garantizan ambas.

Comparación Global: Directos vs. Iterativos: Criterios de selección para ingeniería de procesos y reservorios

Método	Tipo	Flops / Paso	Memoria RAM	Uso Recomendado
Eliminación Gauss (SPP)	Directo	$\frac{2}{3}n^3$ (total)	$\mathcal{O}(n^2)$	Sistemas densos $n < 5000$
Factorización Cholesky	Directo	$\frac{1}{3}n^3$ (total)	$\frac{1}{2}n^2$	Sistemas densos SPD
Algoritmo de Thomas	Directo	$5n$ (total)	$\mathcal{O}(n)$	1D Difusión / Tridiagonal
Jacobi	Iterativo	$\mathcal{O}(\text{nnz})$	$2n$	Paralelismo masivo en GPU
Gauss-Seidel	Iterativo	$\mathcal{O}(\text{nnz})$	n (in-place)	Suavizador / Matrices SPD
Gradiente Conjugado / GMRES	Krylov	$\mathcal{O}(\text{nnz})$	Pocos vectores	Mallas 3D gigantes ($n > 10^6$)

Regla de Oro en Computación Científica

Para mallas discretizadas de EDPs en 2D y 3D, el factor de llenado (*fill-in*) arruina la esparcidad en los métodos directos. Los esquemas iterativos preconditionados son la única alternativa escalable viable.

Resumen y Conclusiones de la Sesión

Estabilidad de métodos directos: El pivoteo parcial escalado (SPP) de Kincaid es imprescindible para evitar que diferencias de escala en las variables destruyan la precisión numérica.

Factorizaciones reutilizables: $PA = LU$ y Cholesky desacoplan el costo volumétrico $\mathcal{O}(n^3)$ de la matriz del costo $\mathcal{O}(n^2)$ por cada vector de condiciones de frontera.

El engaño del residuo: Un residuo $\|b - Ax\| \approx 0$ no asegura exactitud en sistemas mal condicionados ($\kappa(A) \gg 1$).

Unificación formal GLIS: Todos los métodos estacionarios clásicos provienen de un splitting $A = M - N$, con matriz de transferencia $T_M = I - M^{-1}A$.

Criterio espectral definitivo: La convergencia iterativa universal está estrictamente condicionada a que $\rho(T_M) < 1$.

Estructuras físicas favorables: Las matrices simétricas definidas positivas y diagonalmente dominantes, habituales en conservación de flujo en medios porosos, garantizan convergencia robusta.

Referencias Bibliográficas I

- [1] Gene H. Golub y Charles F. Van Loan. *Matrix Computations*. 4.^a ed. The Johns Hopkins University Press, 2013.
- [2] David Kincaid y Ward Cheney. *Numerical Analysis: Mathematics of Scientific Computing*. 3.^a ed. Brooks/Cole, 2002.
- [3] Abner J. Salgado y Steven M. Wise. *Multigrid Methods: A Mostly Matrix-Based Approach*. University of Tennessee Lecture Notes, 2024.
- [4] Jon Shiach. *Linear Algebra*. Manchester Metropolitan University. 2024. URL: <https://www.manchester.ac.uk/staff/jon-shiach/teaching/linear-algebra/>.
- [5] Jon Shiach. *Runge-Kutta Methods and Numerical Ordinary Differential Equations*. Manchester Metropolitan University. 2024. URL: <https://www.manchester.ac.uk/staff/jon-shiach/teaching/runge-kutta-methods-and-numerical-ordinary-differential-equations/>.