Métodos Numéricos PM 311 A

Sistemas de Ecuaciones Lineales: Modelado, Métodos Directos y Condicionamiento

https://pm-311.github.io

Prof. Fidel Jara Huanca

Facultad de Ingeniería de Petróleo, Gas Natural y Petroquímica, Universidad Nacional de Ingeniería

Martes, 22 de septiembre de 2026

Índice

Motivación y Modelado Matricial

Métodos Directos y Factorizaciones

Condicionamiento y Análisis de Sensibilidad

Competencias de la sesión

Al finalizar la clase, el estudiante de ingeniería:

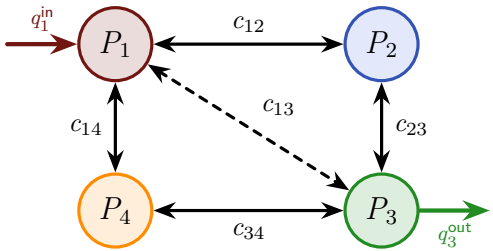
1. **Formula y clasifica** sistemas de ecuaciones algebraicas lineales $Ax = b$ provenientes de modelos físicos de ingeniería y transporte en medios porosos.
2. **Aplica y analiza** métodos directos de factorización (LU, Cholesky, Thomas) y reconoce el papel crítico del pivoteo escalado (SPP) para la estabilidad numérica.
3. **Evalúa el condicionamiento** $\kappa(A)$ y cuantifica la discrepancia entre la norma del residuo y el error relativo de la solución calculada.



Figura: Descarga de diapositivas y código en Python.

Motivación Física: Red de distribución de flujo y presiones nodales

En ingeniería de yacimientos y transporte por tuberías, la distribución estacionaria de presiones en una red interconectada de nodos obedece al balance de masa y la ley de flujo (Darcy / Hagen-Poiseuille):



Para cada nodo i, el caudal neto acumulado es nulo:

$$\sum_{j \in \mathcal{V}(i)} c_{ij} \left(P_i - P_j\right) = q_i^{\text{net}}. \tag{1}$$

Sistema Lineal Estructurado

Agrupando las presiones nodales $x = [P_1, P_2, \ldots, P_n]^T$, se obtiene:

$$Ax = b, \quad A \in \mathbb{R}^{n \times n}, \quad b \in \mathbb{R}^n. \tag{2}$$

donde la matriz de coeficientes A exhibe propiedades estructurales fundamentales:

- **Simetría**: $a_{ij} = a_{ji} = -c_{ij}$ para $i \neq j$.
- **Diagonal dominante**: $a_{ii} = \sum_{j \neq i} c_{ij}$.
- **Esparcidad (Sparsity)**: La inmensa mayoría de entradas son nulas ($a_{ij} = 0$) cuando no existe conexión física directa.

La disyuntiva del cálculo numérico

¿Conviene resolver $Ax = b$ mediante métodos **directos** (álgebra finita exacta salvo redondeo) o métodos **iterativos** (aproximaciones sucesivas)?

Taxonomía de Sistemas Lineales: Dimensiones, esparcidad y factor de llenado (fill-in)

Métodos Directos vs. Métodos Iterativos

Directos (Gauss, LU, Cholesky): Computan la solución exacta en un número finito de operaciones aritméticas en aritmética de precisión infinita.

- Ideales para matrices densas de tamaño moderado ($n \leq 10^4$).
- En matrices esparcidas causan **llenado** (*fill-in*): ceros originales se transforman en entradas no nulas, saturando la memoria RAM.

Iterativos (Jacobi, Gauss-Seidel, Gradiente Conjugado): Generan una secuencia $\{x^{(k)}\}_{k=0}^{\infty}$ tal que $x^{(k)} \to x^*$.

- Preservan la esparcidad (solo requieren productos matriz-vector Av).
- Imprescindibles para simulaciones 3D donde $n \sim 10^6 - 10^8$.

Complejidad Computacional Teórica

Para un sistema con $A \in \mathbb{R}^{n \times n}$:

Método	**Flops Operacionales**	**Memoria Requerida**
Eliminación Gauss / LU	$\frac{2}{3}n^3 + \mathcal{O}(n^2)$	$\mathcal{O}(n^2)$ (densa)
Cholesky (A SPD)	$\frac{1}{3}n^3 + \mathcal{O}(n^2)$	$\frac{1}{2}n^2$
Thomas (Tridiagonal)	$5n$	$\mathcal{O}(n)$
Paso Iterativo (Esparcido)	$\mathcal{O}(\text{nnz}(A))$	$\mathcal{O}(\text{nnz}(A))$

Preguntas esenciales de diseño algorítmico

1. ¿Cuándo un método directo es numéricamente estable?
2. ¿Cómo influyen las perturbaciones en los datos A y b?
3. ¿Bajo qué condiciones converge un esquema iterativo?

Eliminación Gaussiana y Operaciones Elementales: Matriz aumentada, operaciones por filas y forma escalonada (REF)

Operaciones Elementales por Filas (EROs – [3])

Para resolver el sistema lineal $Ax = b$, se construye la matriz aumentada $(A \mid b) \in \mathbb{R}^{n\times(n+1)}$. Las tres operaciones elementales que preservan el conjunto solución son:

- **Tipo I (Intercambio)**: Intercambiar dos filas $(R_i \leftrightarrow R_j)$.
- **Tipo II (Escalamiento)**: Multiplicar una fila por un escalar no nulo $(R_i \leftarrow cR_i,\ c \neq 0)$.
- **Tipo III (Eliminación)**: Sumar a una fila un múltiplo escalar de otra $(R_i \leftarrow R_i - m_{ik}R_k)$.

El objetivo es reducir $(A \mid b)$ a la **forma escalonada por filas** (Row Echelon Form, REF) $(U \mid \tilde{b})$.

Algoritmo y Sustitución Regresiva ([2, 3])

Para $k = 1, \ldots, n-1$, los multiplicadores son:

$$m_{ik} := \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}, \quad (i = k+1, \ldots, n), \tag{3}$$

aplicando $R_i \leftarrow R_i - m_{ik}R_k$. Luego, se despejan las incógnitas desde x_n hasta x_1:

$$x_n = \frac{\tilde{b}_n}{u_{nn}}, \quad x_i = \frac{1}{u_{ii}}\left(\tilde{b}_i - \sum_{j=i+1}^{n} u_{ij}x_j\right). \tag{4}$$

Interpretación Matricial ([1])

Cada etapa equivale a $M_k = I - m_k e_k^T$, tal que $M_{n-1}\cdots M_1 A = U$.

Falla por escala en pivoteo simple

Considere en aritmética de 3 dígitos de mantisa:

$$\begin{bmatrix} 0.0001 & 1.000 \\ 1.000 & 1.000 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.000 \\ 2.000 \end{bmatrix}.$$

Multiplicador $m_{21} = \frac{1.000}{0.0001} = 10^4$. La segunda ecuación produce:

$$(1 - 10^4)x_2 = 2 - 10^4 \implies -10^4 x_2 = -10^4 \implies x_2 = 1.$$

Luego $x_1 = \frac{1-1(1)}{0.0001} = 0$, ¡cuando la solución exacta es $x_1 \approx 1.0001$, $x_2 \approx 0.9999$! ($100\,\%$ de error).

Pivoteo Parcial Escalado (SPP – [2])

Evita el sesgo por unidades físicas heterogéneas sin intercambiar físicamente las filas en memoria:

1. **Vector de escala inicial**:

$$s_i := \max_{1 \le j \le n} |a_{ij}|, \quad (i = 1, \ldots, n). \tag{5}$$

2. **Vector de índices (permutación)**: $p = [1, 2, \ldots, n]^T$.
3. En el paso k, se busca el renglón candidato $\ell \ge k$ tal que:

$$\frac{|a_{p_\ell,k}|}{s_{p_\ell}} = \max_{k \le i \le n} \frac{|a_{p_i,k}|}{s_{p_i}}. \tag{6}$$

4. Se intercambian únicamente los punteros $p_k \leftrightarrow p_\ell$.

Descomposición LU (Algoritmo de Doolittle): Formulación explícita de coeficientes y sustituciones ([4])

Fórmulas Explícitas de Factorización ([4])

Fijando $\ell_{ii} = 1$ en $A = LU$, para cada columna $j = 1, \ldots, n$:

$$u_{ij} = a_{ij} - \sum_{k=1}^{i-1} \ell_{ik} u_{kj}, \quad (i = 1, \ldots, j), \tag{7}$$

$$\ell_{ij} = \frac{1}{u_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} \ell_{ik} u_{kj} \right), \quad (i = j+1, \ldots, n). \tag{8}$$

El término diagonal u_{jj} actúa como pivote ($u_{jj} \neq 0$). Con pivoteo general: $PA = LU$ ([1]).

Algoritmo de Solución en Dos Fases ([4])

Para resolver $Ax = b$ una vez conocido $A = LU$:

1. **Sustitución progresiva** ($Ly = b$):

$$y_1 = b_1, \quad y_i = b_i - \sum_{j=1}^{i-1} \ell_{ij} y_j, \quad (i = 2, \ldots, n). \tag{9}$$

2. **Sustitución regresiva** ($Ux = y$):

$$x_n = \frac{y_n}{u_{nn}}, \quad x_i = \frac{1}{u_{ii}} \left(y_i - \sum_{j=i+1}^{n} u_{ij} x_j \right). \tag{10}$$

Estructuras Especiales: Cholesky y Thomas: Explotando simetría, positividad y bandas estrechas

Factorización de Cholesky (A SPD)

Si $A = A^T$ y es definida positiva ($x^T Ax > 0, \forall x \neq 0$):

$$A = LL^T, \tag{11}$$

donde L es triangular inferior con elementos diagonales estrictamente positivos:

$$\ell_{kk} = \sqrt{a_{kk} - \sum_{j=1}^{k-1} \ell_{kj}^2}, \tag{12}$$

$$\ell_{ik} = \frac{1}{\ell_{kk}} \left(a_{ik} - \sum_{j=1}^{k-1} \ell_{ij}\ell_{kj} \right), \quad i > k. \tag{13}$$

Propiedades clave:

- Costo: $\frac{1}{3}n^3$ flops ($\frac{1}{2}$ del costo de LU).
- **Estabilidad incondicional**: No requiere pivoteo.

Sistemas Tridiagonales: Algoritmo de Thomas

Surgen en diferencias finitas para difusión unidimensional:

$$\begin{bmatrix} d_1 & c_1 & & \\ a_1 & d_2 & c_2 & \\ & \ddots & \ddots & \ddots \\ & & a_{n-1} & d_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

Algoritmo en $\mathcal{O}(n)$ flops ([2]):

- Modificación hacia adelante: $d'_i = d_i - \frac{a_{i-1}}{d'_{i-1}} c_{i-1}$, $b'_i = b_i - \frac{a_{i-1}}{d'_{i-1}} b'_{i-1}$.
- Sustitución regresiva: $x_n = \frac{b'_n}{d'_n}$, $\quad x_i = \frac{b'_i - c_i x_{i+1}}{d'_i}$.

Normas Matriciales y Número de Condición: Midiendo la amplificación intrínseca de incertidumbres

Normas Inducidas o Subordinadas

Dada una norma vectorial $\|\cdot\|$, la norma matricial inducida se define como:

$$\|A\| := \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{\|x\|=1} \|Ax\|. \tag{14}$$

Casos fundamentales en computación:

- $\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^{n} |a_{ij}|$ (máxima suma por columnas).
- $\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^{n} |a_{ij}|$ (máxima suma por filas).
- $\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \sigma_{\max}(A)$ (valor singular máximo).

Definición 1 (Número de Condición de una Matriz ([1])).

Para $A \in \mathbb{R}^{n \times n}$ no singular:

$$\kappa(A) := \|A\| \, \|A^{-1}\|. \tag{15}$$

Propiedades esenciales:

- $\kappa(A) \geq \|AA^{-1}\| = \|I\| = 1$.
- $\kappa(I) = 1$.
- Para matrices ortogonales Q: $\kappa_2(Q) = 1$.

Significado Físico y Numérico

$\kappa(A)$ cuantifica la sensibilidad del sistema frente a perturbaciones en los datos. Una regla empírica fundamental: si $\kappa_{10}(A) \approx 10^p$, se pierden hasta p cifras significativas de precisión en la solución calculada.

Teorema de Perturbación y Residuo vs. Error: ¿Un residuo pequeño garantiza una solución precisa?

Teorema 2 (Cota Fundamental del Error Relativo).

Sea $Ax = b$ y $(A + \Delta A)(x + \Delta x) = b + \Delta b$. Si $\|\Delta A\| < \frac{1}{\|A^{-1}\|}$, entonces:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A)\frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right). \tag{16}$$

En particular, si solo se perturba el vector de carga b ($\Delta A = 0$):

$$\frac{\|\Delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\Delta b\|}{\|b\|}. \tag{17}$$

La Paradoja del Residuo ([1, 2])

Sea $\hat{x}$ una solución aproximada. Definimos:

- **Vector de error**: $e := x - \hat{x}$.
- **Vector de residuo**: $r := b - A\hat{x} = A(x - \hat{x}) = Ae$.

Como $e = A^{-1}r$, acotamos:

$$\frac{1}{\kappa(A)} \frac{\|r\|}{\|b\|} \leq \frac{\|e\|}{\|x\|} \leq \kappa(A) \frac{\|r\|}{\|b\|}. \tag{18}$$

Conclusión Crucial

Si $\kappa(A) \gg 1$ (sistema mal condicionado), un algoritmo puede producir un residuo insignificante ($\|r\| \approx 10^{-14}$) teniendo un error inaceptable ($\|e\| \approx 10^{-2}$). ¡Monitorear solo el residuo es engañoso!

Resumen y Conclusiones de la Sesión

Estabilidad de métodos directos: El pivoteo parcial escalado (SPP) de Kincaid es imprescindible para evitar que diferencias de escala en las variables destruyan la precisión numérica.

Factorizaciones reutilizables: $PA = LU$ y Cholesky desacoplan el costo volumétrico $\mathcal{O}(n^3)$ de la matriz del costo $\mathcal{O}(n^2)$ por cada vector de condiciones de frontera.

Matrices tridiagonales: El algoritmo de Thomas resuelve sistemas tridiagonales en tiempo lineal $\mathcal{O}(n)$, óptimo para discretizaciones 1D en ingeniería.

El engaño del residuo: Un residuo $\|b - Ax\| \approx 0$ no asegura exactitud en sistemas mal condicionados ($\kappa(A) \gg 1$).

Referencias Bibliográficas I

[1] Gene H. Golub y Charles F. Van Loan. *Matrix Computations*. 4.ª ed. The Johns Hopkins University Press, 2013.

[2] David Kincaid y Ward Cheney. *Numerical Analysis: Mathematics of Scientific Computing*. 3.ª ed. Brooks/Cole, 2002.

[3] Jon Shiach. *Linear Algebra*. Manchester Metropolitan University. 2024. URL: .

[4] Jon Shiach. *Runge-Kutta Methods and Numerical Ordinary Differential Equations*. Manchester Metropolitan University. 2024. URL: .