# Métodos Numéricos PM 311 A

## Sistemas de Ecuaciones Lineales: Métodos Iterativos Estacionarios

https://pm-311.github.io

Prof. Fidel Jara Huanca

Facultad de Ingeniería de Petróleo, Gas Natural y Petroquímica, Universidad Nacional de Ingeniería

Martes, 29 de septiembre de 2026

# Índice

Métodos Iterativos Estacionarios (GLIS)

Teoría Espectral de Convergencia

Comparación Global y Criterios de Selección

## Competencias de la sesión

Al finalizar la clase, el estudiante de ingeniería:

1. **Comprende la necesidad** de esquemas iterativos frente al factor de llenado (*fill-in*) en matrices ralas de gran escala ($n \gg 10^4$).
2. **Formula e implementa** esquemas iterativos estacionarios clásicos (Jacobi, Gauss-Seidel, Richardson) enmarcados en la teoría general de splitting (GLIS).
3. **Analiza la convergencia** mediante el radio espectral $\rho(T_M) < 1$ y calcula tasas asintóticas de reducción de error.
4. **Aplica criterios suficientes** de dominancia diagonal estricta (EDD) y positividad simétrica (SPD) para garantizar estabilidad.
5. **Selecciona la estrategia óptima** evaluando compromisos entre complejidad por paso, huella de memoria RAM y paralelismo computacional.



Figura: Descarga de diapositivas y código en Python.

## **Esquemas Lineales Iterativos Generales (GLIS):** El marco formal del desdoblamiento matricial (Splitting)

### Teoría del Desdoblamiento ([3])

Para resolver $Ax = b$, consideramos un **splitting**:

$$A = M - N, \tag{1}$$

donde $M \in \mathbb{R}^{n\times n}$ es una matriz **no singular** y fácil de invertir.
Entonces:

$$(M - N)x = b \iff Mx = Nx + b. \tag{2}$$

Esto induce de forma natural el esquema iterativo:

$$Mx^{(k+1)} = Nx^{(k)} + b, \quad k \geq 0. \tag{3}$$

### Definición 1 (Matriz de Transferencia de Error ([3])).

Multiplicando por $M^{-1}$:

$$x^{(k+1)} = T_M x^{(k)} + c_M, \tag{4}$$

donde:

$$T_M := M^{-1}N = M^{-1}(M - A) = I - M^{-1}A, \tag{5}$$

$$c_M := M^{-1}b. \tag{6}$$

$T_M$ se denomina **matriz de iteración** o matriz de propagación de error.

### Ecuación del Error

Siendo $x$ la solución exacta ($x = T_M x + c_M$) y $e^{(k)} := x^{(k)} - x$:

$$e^{(k+1)} = T_M e^{(k)} = T_M^{k+1} e^{(0)}. \tag{7}$$

## Descomposición Estándar de la Matriz $A$

Separamos la matriz en sus partes diagonal, triangular inferior y superior:

$$A = D - L - U, \tag{8}$$

donde $D = \mathrm{diag}(a_{ii})$, $-L$ contiene los elementos estrictamente bajo la diagonal y $-U$ sobre ella.

## Método de Jacobi ([2, 3])

Tomamos el preacondicionador diagonal:

$$M_J := D, \quad N_J := L + U. \tag{9}$$

La matriz de iteración de Jacobi es:

$$T_J = D^{-1}(L + U) = I - D^{-1}A. \tag{10}$$

## Fórmula por Componentes de Jacobi

Para cada fila $i = 1, \ldots, n$:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right). \tag{11}$$

**Ventajas y Desventajas:**

- **Totalmente paralelizable**: Cada coordenada $x_i^{(k+1)}$ se calcula de manera independiente sin esperar a las demás.
- Requiere almacenar dos vectores completos en memoria ($x^{(k)}$ y $x^{(k+1)}$).
- Convergencia usualmente lenta en mallas finas.

# **Método de Gauss-Seidel Progresivo y Regresivo:** Aceleración mediante actualización inmediata en memoria

## Gauss-Seidel Progresivo (Forward GS)

Aprovecha de inmediato las componentes $x_1^{(k+1)}, \ldots, x_{i-1}^{(k+1)}$ ya computadas en el paso actual:

$$M_{GS} \coloneqq D - L, \quad N_{GS} \coloneqq U. \tag{12}$$

Forma matricial:

$$(D - L)x^{(k+1)} = Ux^{(k)} + b. \tag{13}$$

Matriz de iteración:

$$T_{GS} = (D - L)^{-1} U. \tag{14}$$

**Formulación escalar:**

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left( b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^{n} a_{ij} x_j^{(k)} \right). \tag{15}$$

## Gauss-Seidel Regresivo (Backward GS)

Actualiza las componentes en orden inverso ($i = n, n-1, \ldots, 1$):

$$M_{BGS} \coloneqq D - U, \quad N_{BGS} \coloneqq L. \tag{16}$$

## Comparación Operativa

- **Ahorro de memoria**: Se sobreescribe el vector $x$ *in-place* en un único arreglo.
- **Dependencia secuencial**: No es directamente vectorizable sin coloreado de nodos (Red-Black ordering).
- Típicamente converge el doble de rápido que Jacobi: $\rho(T_{GS}) \approx \rho(T_J)^2$.

# **Método de Richardson y Relajación Amortiguada:** Ajuste del tamaño de paso y estabilización de la dinámica

## Método de Richardson Clásico ([3])

Se elige $M_\omega = \frac{1}{\omega} I$, donde $\omega > 0$ es un parámetro de paso o relajación:

$$x^{(k+1)} = x^{(k)} + \omega \left(b - Ax^{(k)}\right) = x^{(k)} + \omega r^{(k)}. \tag{17}$$

Matriz de iteración:

$$T_\omega = I - \omega A. \tag{18}$$

**Interpretación en optimización:** Equivale al método del **descenso por gradiente** con paso fijo para minimizar la función cuadrática:

$$\Phi(x) = \frac{1}{2} x^T A x - x^T b. \tag{19}$$

## Jacobi Amortiguado (Damped Jacobi)

Interpola linealmente entre la iteración previa y la propuesta de Jacobi:

$$x^{(k+1)} = (1-\omega)x^{(k)} + \omega x_J^{(k+1)}. \tag{20}$$

Matriz asociada:

$$T_{J,\omega} = (1-\omega)I + \omega T_J = I - \omega D^{-1} A. \tag{21}$$

## Propiedad Suavizadora (Smoother)

En métodos multigrid, el Jacobi amortiguado (con $\omega = \frac{2}{3}$) no busca resolver el sistema globalmente, sino **amortiguar rápidamente las componentes de alta frecuencia** del error.

## El Teorema Espectral de Convergencia: El radio espectral $\rho(T)$ como juez definitivo

### Definición 2 (Radio Espectral).

Para cualquier matriz cuadrada $T \in \mathbb{R}^{n\times n}$ con autovalores $\lambda_1, \ldots, \lambda_n \in \mathbb{C}$:

$$\rho(T) \coloneqq \max_{1\le i\le n} |\lambda_i(T)|. \tag{22}$$

### Teorema 3 (Teorema Maestro de Convergencia de GLIS).

El esquema iterativo lineal estacionario $x^{(k+1)} = Tx^{(k)} + c$ converge a la solución única $x = (I - T)^{-1}c$ para **cualquier** vector inicial $x^{(0)}$ si y sólo si:

$$\rho(T) < 1. \tag{23}$$

### Esquema de la Demostración ([3])

La dinámica del error está regida por:

$$e^{(k)} = T^k e^{(0)}. \tag{24}$$

Por la Forma Canónica de Jordan de $T = VJV^{-1}$:

$$T^k = VJ^kV^{-1}. \tag{25}$$

Los bloques de Jordan asociados a autovalores $\lambda$ satisfacen:

$$J_i^k \to 0 \quad (k \to \infty) \iff |\lambda_i| < 1.$$

Por tanto, $\lim_{k\to\infty} T^k = 0 \iff \rho(T) < 1$. ■

### Tasa Asintótica de Convergencia

La ganancia de dígitos exactos por iteración es:

$$R_\infty(T) \coloneqq -\log_{10}(\rho(T)). \tag{26}$$

## **Criterios Prácticos de Convergencia:** Matrices diagonalmente dominantes y definidas positivas

### Definición 4 (Dominancia Diagonal Estricta por Filas).

Una matriz $A \in \mathbb{R}^{n\times n}$ es estrictamente diagonal dominante (EDD) si:

$$|a_{ii}| > \sum_{j\neq i} |a_{ij}|, \quad \forall i = 1, \ldots, n. \tag{27}$$

### Teorema 5 (Criterio Suficiente de Convergencia ([2])).

Si la matriz de coeficientes $A$ es estrictamente diagonal dominante:

1. $A$ es no singular.
2. El método de **Jacobi** converge ($\|T_J\|_\infty < 1 \implies \rho(T_J) < 1$).
3. El método de **Gauss-Seidel** converge ($\rho(T_{GS}) < 1$).

### Teorema 6 (Teorema de Householder-John / Ostrowski-Reich).

Si $A$ es una matriz simétrica y definida positiva (SPD), y el factor de desdoblamiento $M$ cumple que $M + M^T - A$ es SPD, entonces:

$$\rho(T_M) < 1. \tag{28}$$

**Consecuencia fundamental:** Para cualquier matriz SPD, el método de Gauss-Seidel converge **incondicionalmente**, sin importar si es diagonalmente dominante o no.

### Cuidado con la intuición

Existen matrices donde Jacobi converge y Gauss-Seidel diverge, y viceversa. La dominancia diagonal o la positividad simétrica garantizan ambas.

## **Comparación Global: Directos vs. Iterativos:** Criterios de selección para ingeniería de procesos y reservorios

| Método | Tipo | Flops / Paso | Memoria RAM | Uso Recomendado |
|---|---|---|---|---|
| **Eliminación Gauss (SPP)** | Directo | $\frac{2}{3}n^3$ (total) | $\mathcal{O}(n^2)$ | Sistemas densos $n < 5000$ |
| **Factorización Cholesky** | Directo | $\frac{1}{3}n^3$ (total) | $\frac{1}{2}n^2$ | Sistemas densos SPD |
| **Algoritmo de Thomas** | Directo | $5n$ (total) | $\mathcal{O}(n)$ | 1D Difusión / Tridiagonal |
| **Jacobi** | Iterativo | $\mathcal{O}(\text{nnz})$ | $2n$ | Paralelismo masivo en GPU |
| **Gauss-Seidel** | Iterativo | $\mathcal{O}(\text{nnz})$ | $n$ (in-place) | Suavizador / Matrices SPD |
| **Gradiente Conjugado / GMRES** | Krylov | $\mathcal{O}(\text{nnz})$ | Pocos vectores | Mallas 3D gigantes ($n > 10^6$) |

### Regla de Oro en Computación Científica

Para mallas discretizadas de EDPs en 2D y 3D, el factor de llenado (*fill-in*) arruina la esparcidad en los métodos directos. Los esquemas iterativos preacondicionados son la única alternativa escalable viable.

## Resumen y Conclusiones de la Sesión

Unificación formal GLIS: Todos los métodos estacionarios clásicos provienen de un splitting $A = M - N$, con matriz de transferencia $T_M = I - M^{-1}A$.

Criterio espectral definitivo: La convergencia iterativa universal está estrictamente condicionada a que el radio espectral cumpla $\rho(T_M) < 1$.

Estructuras físicas favorables: Las matrices simétricas definidas positivas (SPD) y estrictamente diagonal dominantes (EDD), habituales en conservación de flujo en medios porosos, garantizan convergencia incondicional.

Escalabilidad computacional: Para mallas 2D/3D a gran escala, los esquemas iterativos evitan el *fill-in* catastrófico de los métodos directos con requerimientos de memoria $\mathcal{O}(\text{nnz})$.

## Referencias Bibliográficas I


[1] Gene H. Golub y Charles F. Van Loan. *Matrix Computations*. 4.ª ed. The Johns Hopkins University Press, 2013.

[2] David Kincaid y Ward Cheney. *Numerical Analysis: Mathematics of Scientific Computing*. 3.ª ed. Brooks/Cole, 2002.

[3] Abner J. Salgado y Steven M. Wise. *Multigrid Methods: A Mostly Matrix-Based Approach*. University of Tennessee Lecture Notes, 2024.

[4] Jon Shiach. *Runge-Kutta Methods and Numerical Ordinary Differential Equations*. Manchester Metropolitan University. 2024. URL: